ЛАБОРАТОРНА РОБОТА № 5

ДОСЛІДЖЕННЯ МЕТОДІВ АНСАМБЛЕВОГО НАВЧАННЯ

Мета роботи: *використовуючи спеціалізовані бібліотеки та мову програмування Python дослідити методи ансамблів у машинному навчанні.*

Завдання 1

```
$ python3 random_forests.py --classifier-type rf
```

У процесі виконання цього коду отримайте ***ряд зображень та занесіть їх у звіт***.

Графік вхідних даних. На графіку квадрати, кола та трикутники представляють три класи. Оцініть візуально, що класи значною мірою перекриваються, проте на цьому етапі це нормально. ***Графік занесіть у звіт.***

Зображення на якому відображені границі класифікатора. ***Графік занесіть у звіт.***

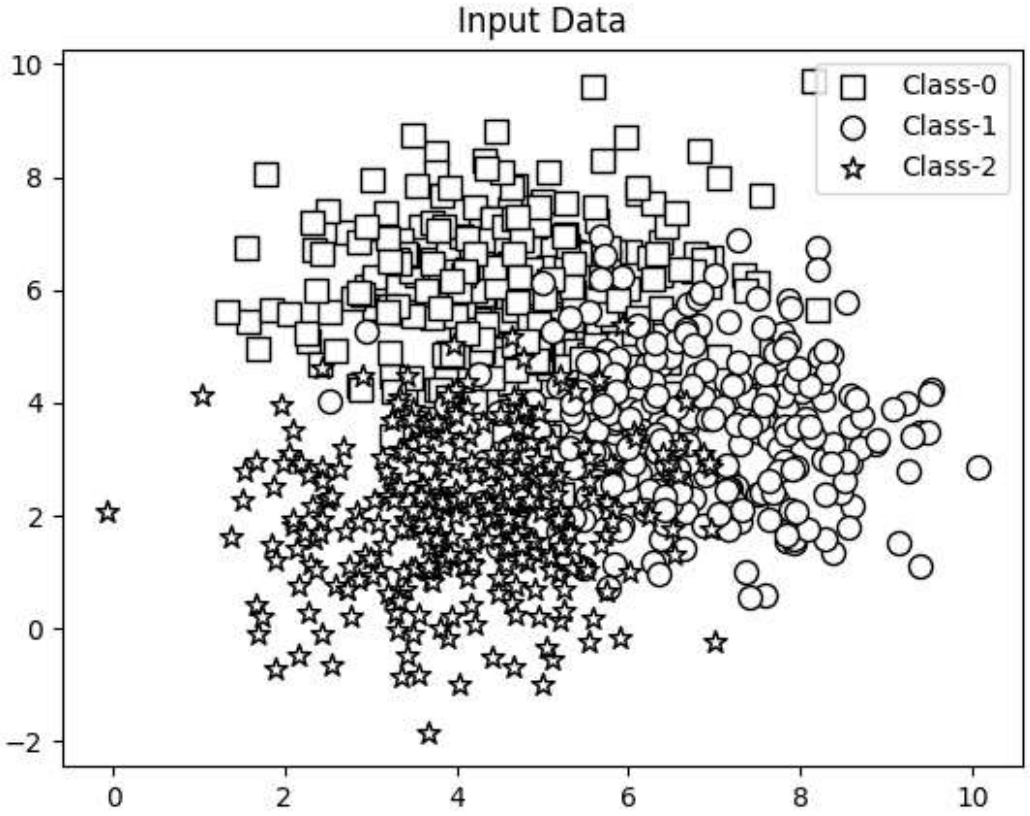

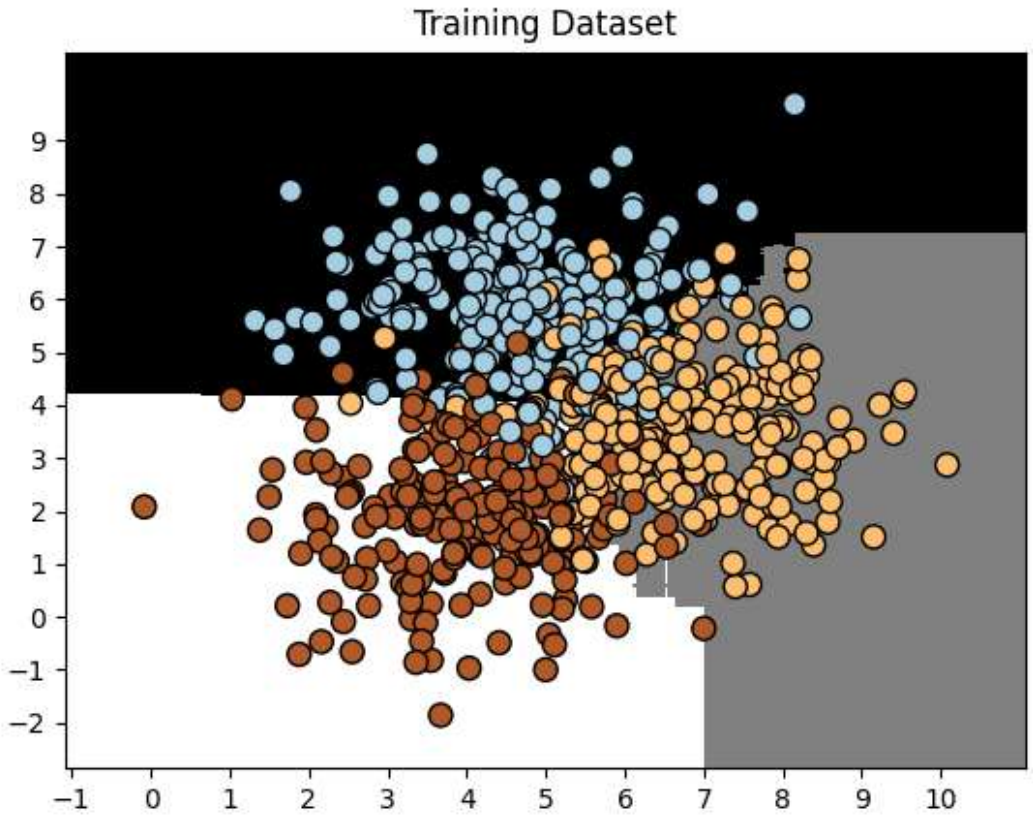
Training Dataset
9
8
7
6
5
4
3
2
1
0
−1
−2
−1
0
1
2
3
4
5
6
7
8
9
10

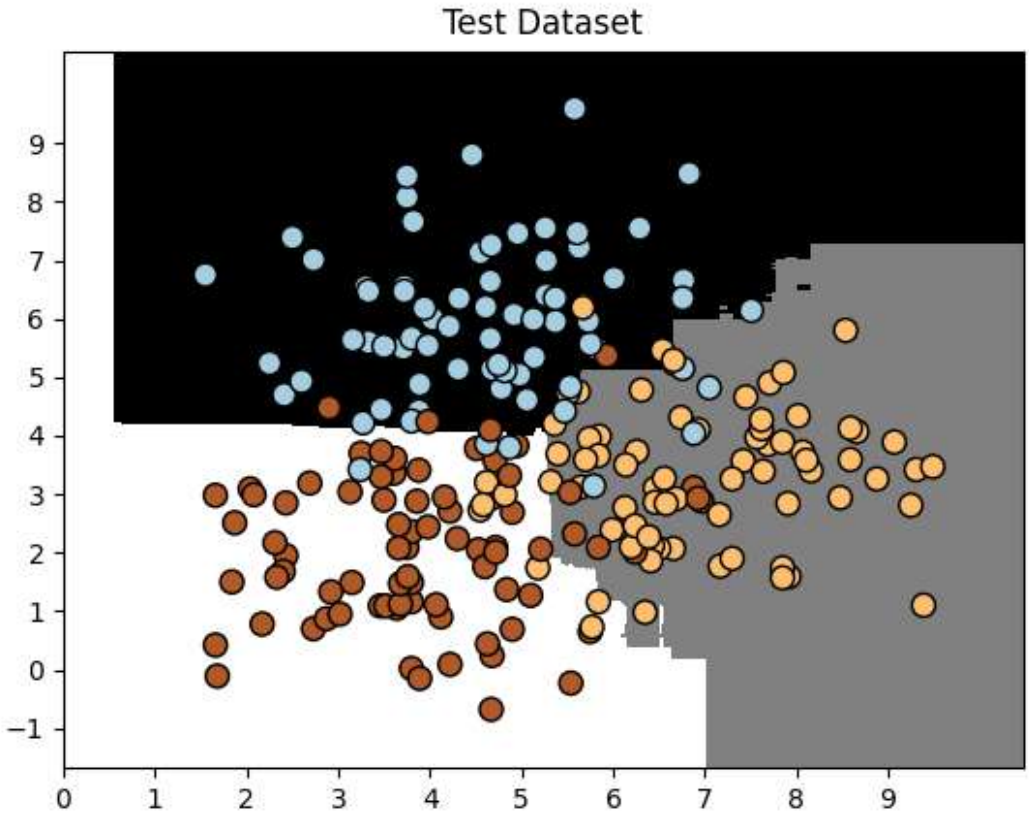
Test Dataset
9
8
7
6
5
4
3
2
1
0
−1
0
1
2
3
4
5
6
7
8
9

```
########################################

Classifier performance on training dataset

              precision    recall  f1-score   support

     Class-0       0.90      0.88      0.89       227
     Class-1       0.84      0.87      0.86       226
     Class-2       0.88      0.87      0.88       222

    accuracy                           0.87       675
   macro avg       0.87      0.87      0.87       675
weighted avg       0.87      0.87      0.87       675

########################################

########################################

Classifier performance on test dataset

              precision    recall  f1-score   support

     Class-0       0.89      0.89      0.89        73
     Class-1       0.85      0.85      0.85        74
     Class-2       0.86      0.86      0.86        78

    accuracy                           0.87       225
   macro avg       0.87      0.87      0.87       225
weighted avg       0.87      0.87      0.87       225

########################################
```

```
$ python3 random_forests.py --classifier-type erf
```

Отримайте зображення то порівняйте його з попереднім. ***Графік занесіть у звіт.*** Зверніть увагу, що в останньому випадку були отримані більш лагідні піки. Це обумовлено тим, що в процесі навчання гранично випадкові ліси мають більше можливостей для вибору оптимальних дерев рішень, тому, як правило, вони забезпечують отримання кращих границь.

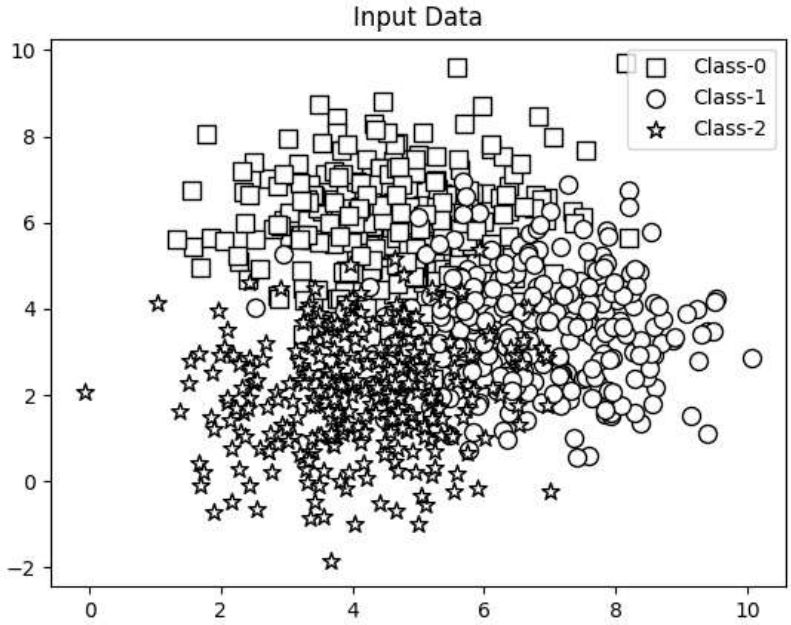

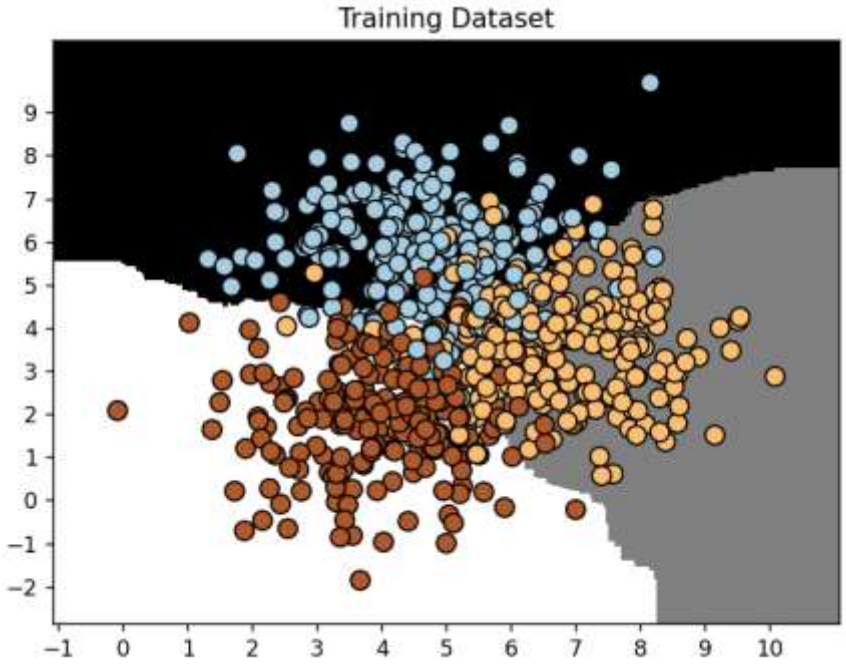

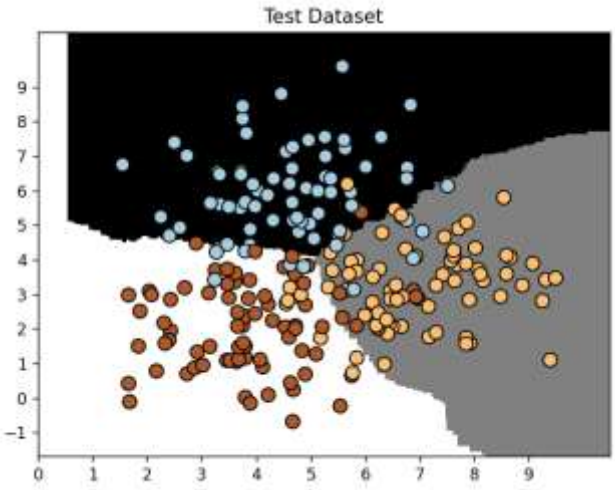


```
########################################

Classifier performance on training dataset

              precision    recall  f1-score   support

     Class-0       0.88      0.84      0.86       227
     Class-1       0.82      0.83      0.83       226
     Class-2       0.84      0.88      0.86       222

    accuracy                           0.85       675
   macro avg       0.85      0.85      0.85       675
weighted avg       0.85      0.85      0.85       675

########################################

########################################

Classifier performance on test dataset

              precision    recall  f1-score   support

     Class-0       0.92      0.84      0.88        73
     Class-1       0.83      0.85      0.84        74
     Class-2       0.84      0.90      0.87        78

    accuracy                           0.86       225
   macro avg       0.87      0.86      0.86       225
weighted avg       0.86      0.86      0.86       225

########################################
```

Результат виконання цього коду із прапором **rf** ***занесіть у звіт***

У вікні терміналу з'явиться виведена інформація ***Скріншот цієї інформації виріжте та занесіть у звіт.***

Для кожної точки даних обчислюється можливість її належності кожному з трьох класів. Ми вибираємо той клас, якому відповідає найвищий рівень довіри.

Результат виконання коду із прапором **erf** ***занесіть у звіт***.

У вікні терміналу з'явиться виведена інформація ***Скріншот цієї інформації виріжте та занесіть у звіт.***

Збережіть код робочої програми під назвою LR_5_task_1.py

Код програми, графік функції та результати оцінки якості занесіть у звіт.

RF:

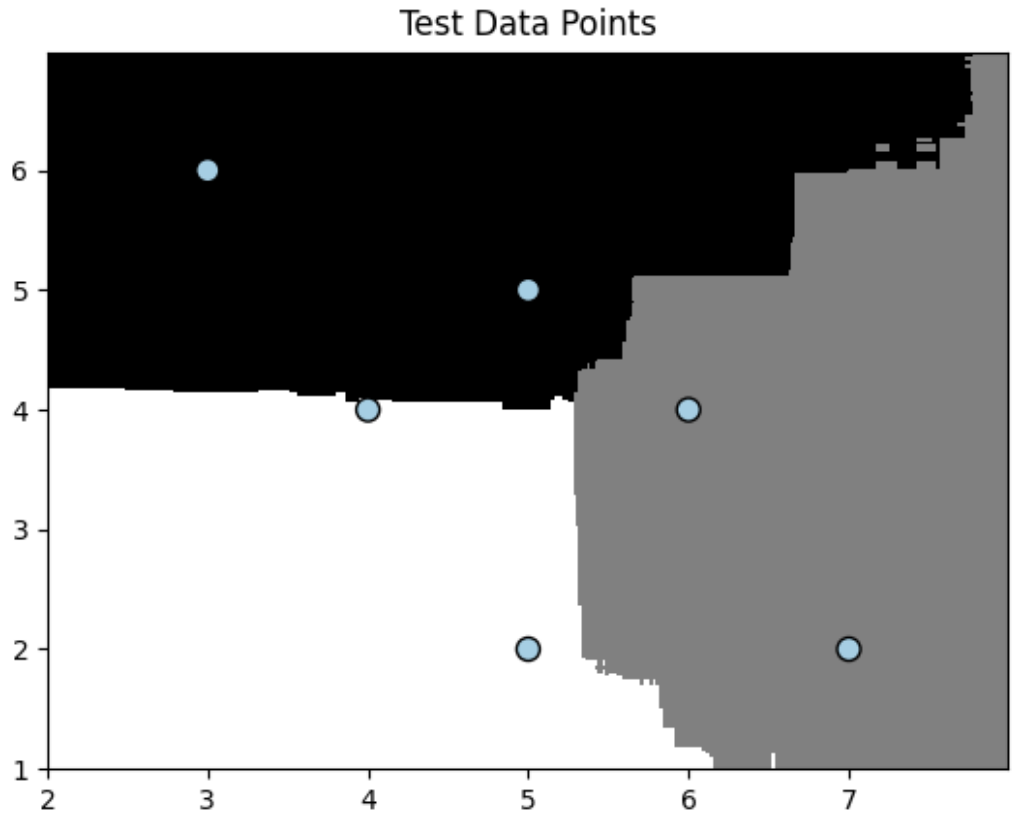

```
Confidence measure:

Datapoint: [5 5]
Predicted class: Class-0

Datapoint: [3 6]
Predicted class: Class-0

Datapoint: [6 4]
Predicted class: Class-1

Datapoint: [7 2]
Predicted class: Class-1

Datapoint: [4 4]
Predicted class: Class-2

Datapoint: [5 2]
Predicted class: Class-2
```

ERF:

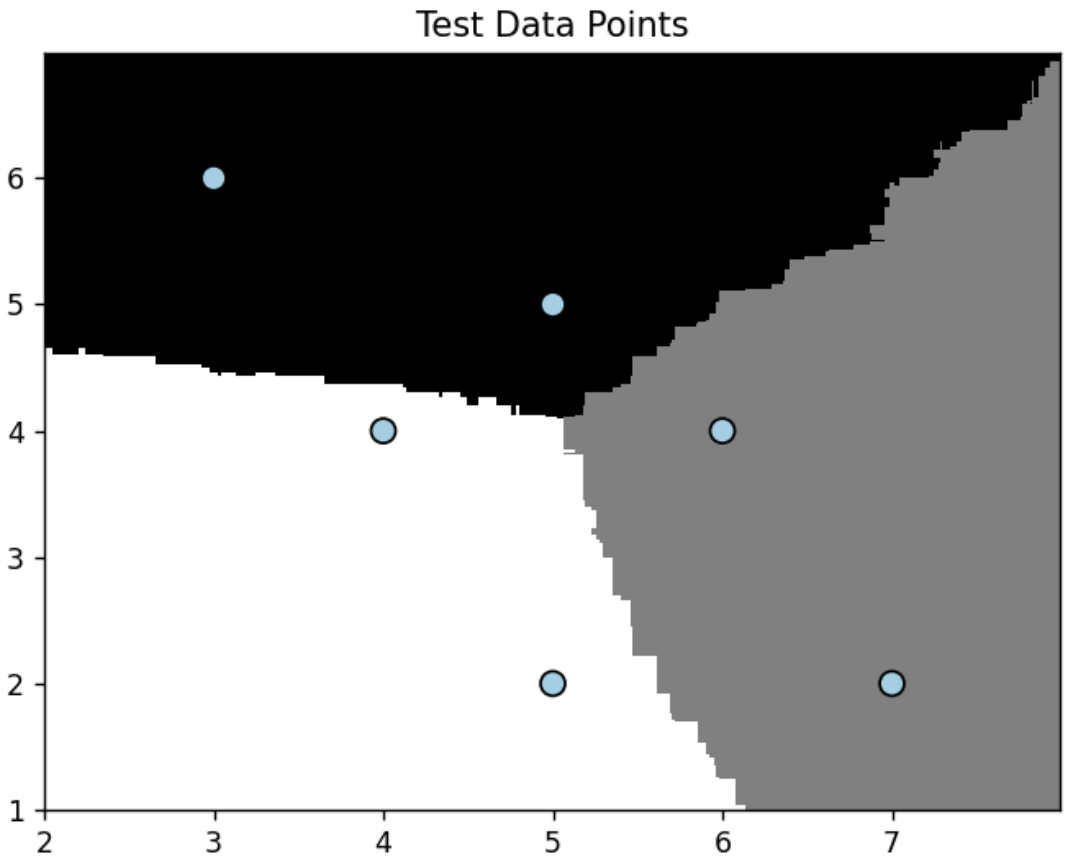

```
Confidence measure:

Datapoint: [5 5]
Predicted class: Class-0

Datapoint: [3 6]
Predicted class: Class-0

Datapoint: [6 4]
Predicted class: Class-1

Datapoint: [7 2]
Predicted class: Class-1

Datapoint: [4 4]
Predicted class: Class-2

Datapoint: [5 2]
Predicted class: Class-2
```

Лістинг:

```
import argparse
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import classification_report
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier,
ExtraTreesClassifier
from utilities import visualize_classifier

def build_arg_parser():
    parser = argparse.ArgumentParser(description='Classify data using
ensemble learning techniques')
    parser.add_argument('--classifier-type', dest='classifier_type',
required=True, choices=['rf', 'erf'],
                        help="Type of classifier to use: 'rf' (Random
Forest) or 'erf' (Extra Random Forest)")
    return parser

def load_data(input_file):
    data = np.loadtxt(input_file, delimiter=',')
```

```
    X, y = data[:, :-1], data[:, -1]
    return X, y

def main():
    # Parsing arguments
    args = build_arg_parser().parse_args()
    classifier_type = args.classifier_type

    # Load dataset
    input_file = 'data_random_forests.txt'
    X, y = load_data(input_file)

    # Input data visualization
    plt.figure()
    markers = ['s', 'o', '*']
    for i, label in enumerate(np.unique(y)):
        class_data = X[y == label]
        plt.scatter(class_data[:, 0], class_data[:, 1], s=75,
facecolors='white',
                    edgecolors='black', linewidth=1, marker=markers[i],
label=f'Class-{int(label)}')
    plt.title('Input Data')
    plt.legend()
    plt.show()

    # Splitting the dataset
    X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.25, random_state=2)

    # Classifier initialization
    params = {'n_estimators': 100, 'max_depth': 4, 'random_state': 0}
    if classifier_type == 'rf':
        classifier = RandomForestClassifier(**params)
    elif classifier_type == 'erf':
        classifier = ExtraTreesClassifier(**params)

    # Training the classifier
    classifier.fit(X_train, y_train)

    # Training dataset visualization
    visualize_classifier(classifier, X_train, y_train, 'Training
Dataset')
```

```
    # Test dataset visualization
    visualize_classifier(classifier, X_test, y_test, 'Test Dataset')

    # Training performance
    print("\n" + "#" * 40)
    print("\nClassifier performance on training dataset\n")
    print(classification_report(y_train, classifier.predict(X_train),
target_names=['Class-0', 'Class-1', 'Class-2']))
    print("#" * 40 + "\n")

    # Test performance
    print("#" * 40)
    print("\nClassifier performance on test dataset\n")
    print(classification_report(y_test, classifier.predict(X_test),
target_names=['Class-0', 'Class-1', 'Class-2']))
    print("#" * 40 + "\n")

    # Test data points visualization
    test_datapoints = np.array([[5, 5], [3, 6], [6, 4], [7, 2], [4, 4],
[5, 2]])
    print("\nConfidence measure:")
    for datapoint in test_datapoints:
        probabilities = classifier.predict_proba([datapoint])[0]
        predicted_class = f"Class-{np.argmax(probabilities)}"
        print(f"\nDatapoint: {datapoint}")
        print(f"Predicted class: {predicted_class}")

    visualize_classifier(classifier, test_datapoints, [0] *
len(test_datapoints), 'Test Data Points')
    plt.show()

if __name__ == '__main__':
    main()
```

Завдання 2.2. Обробка дисбалансу класів

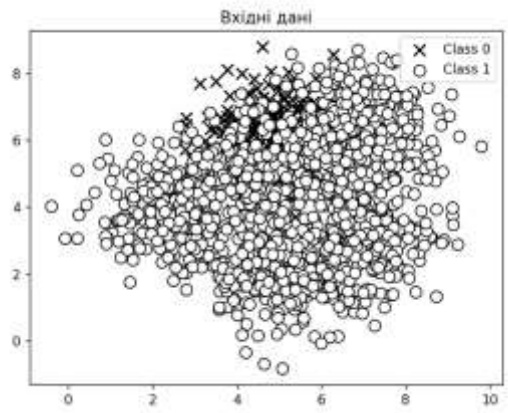
Вхідні дані
Class 0
Class 1

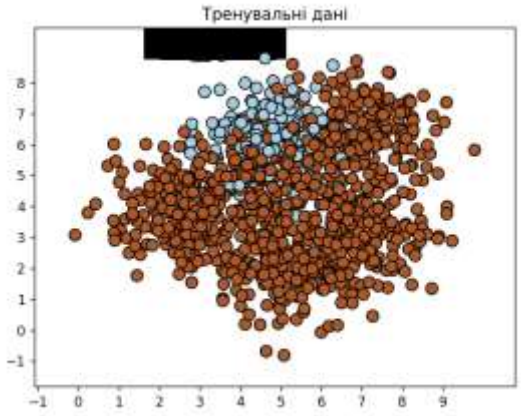
Тренувальні дані

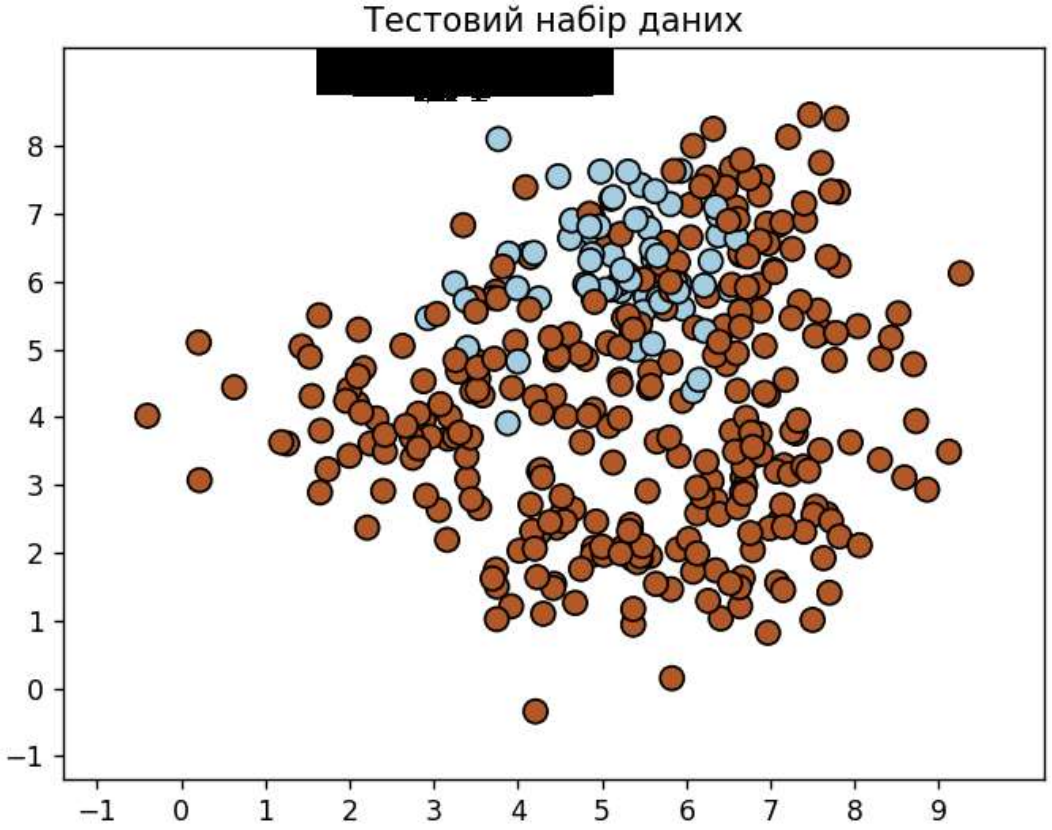
Тестовий набір даних

```
########################################
Classifier performance on training dataset

              precision    recall  f1-score   support

     Class-0       1.00      0.01      0.01       181
     Class-1       0.84      1.00      0.91       944

    accuracy                           0.84      1125
   macro avg       0.92      0.50      0.46      1125
weighted avg       0.87      0.84      0.77      1125

########################################
```

```
              precision    recall  f1-score   support

     Class-0       0.00      0.00      0.00        69
     Class-1       0.82      1.00      0.90       306

    accuracy                           0.82       375
   macro avg       0.41      0.50      0.45       375
weighted avg       0.67      0.82      0.73       375

########################################
```

python3 –W ignore class_imbalence.py:

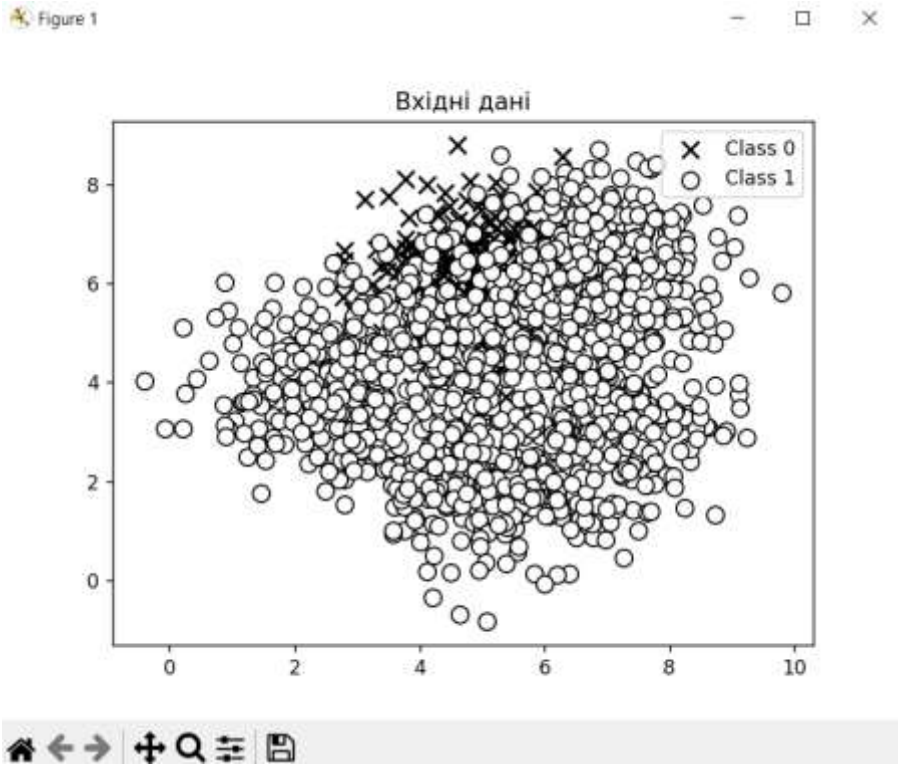

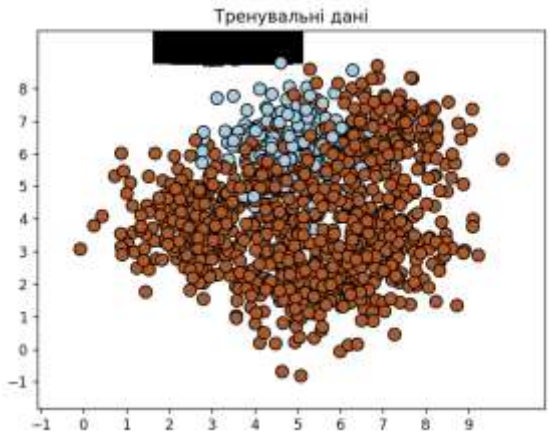

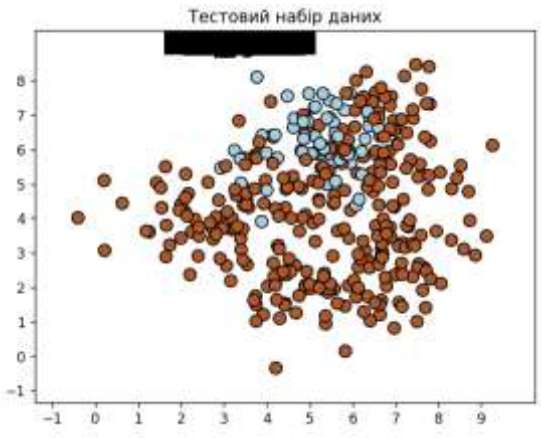


```
########################################
Classifier performance on training dataset

              precision    recall  f1-score   support

     Class-0       1.00      0.01      0.01       181
     Class-1       0.84      1.00      0.91       944

    accuracy                           0.84      1125
   macro avg       0.92      0.50      0.46      1125
weighted avg       0.87      0.84      0.77      1125

########################################

Classifier performance on test dataset

              precision    recall  f1-score   support

     Class-0       0.00      0.00      0.00        69
     Class-1       0.82      1.00      0.90       306

    accuracy                           0.82       375
   macro avg       0.41      0.50      0.45       375
weighted avg       0.67      0.82      0.73       375

########################################
```

python3 class_imbalence.py balance:

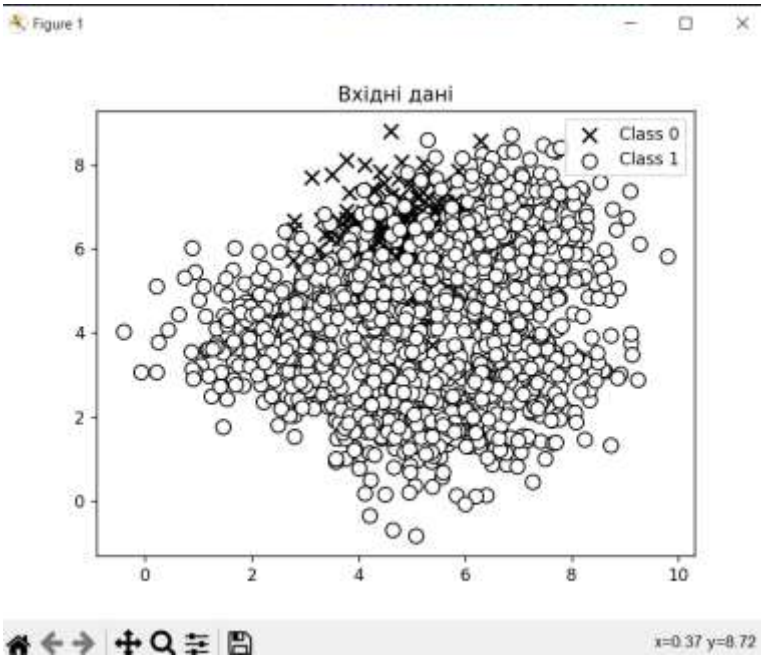

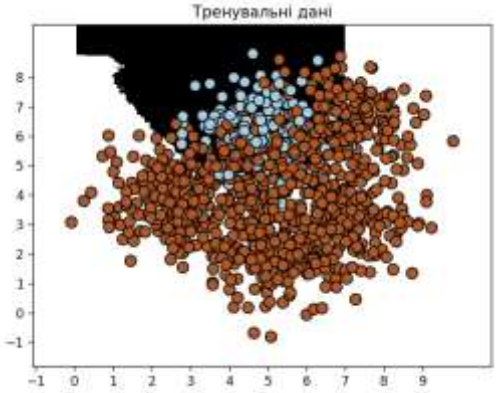

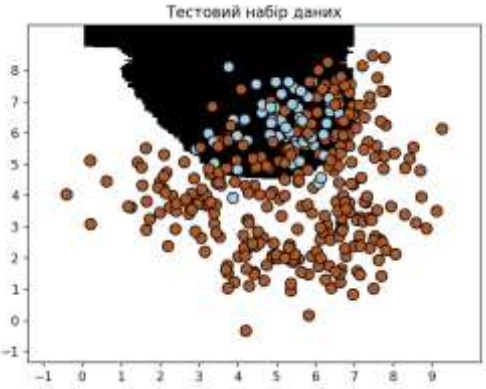


```
############################################
Classifier performance on training dataset

              precision    recall  f1-score   support

     Class-0       0.44      0.93      0.60       181
     Class-1       0.98      0.77      0.86       944

    accuracy                           0.80      1125
   macro avg       0.71      0.85      0.73      1125
weighted avg       0.89      0.80      0.82      1125

############################################
```

```
########################################

Classifier performance on test dataset

              precision    recall  f1-score   support

     Class-0       0.45      0.94      0.61        69
     Class-1       0.98      0.74      0.84       306

    accuracy                           0.78       375
   macro avg       0.72      0.84      0.73       375
weighted avg       0.88      0.78      0.80       375

########################################
```

Лістинг:

```
import sys
import numpy as np
import matplotlib.pyplot as plt
from sklearn.ensemble import ExtraTreesClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report
from utilities import visualize_classifier

def load_data(input_file):
    data = np.loadtxt(input_file, delimiter=',')
    X, y = data[:, :-1], data[:, -1]
    return X, y

def plot_data(X, y):
    class_0 = X[y == 0]
    class_1 = X[y == 1]

    plt.figure()
    plt.scatter(class_0[:, 0], class_0[:, 1], s=75, c='black',
marker='x', label='Class 0')
    plt.scatter(class_1[:, 0], class_1[:, 1], s=75, c='white',
edgecolors='black', marker='o', label='Class 1')
    plt.title("Вхідні дані")
    plt.legend()
    plt.show()

def train_and_evaluate(X, y, balance=False):
```

```
    # Split the data into training and testing sets
    X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.25, random_state=5)

    # Define classifier parameters
    params = {'n_estimators': 100, 'max_depth': 4, 'random_state': 0}
    if balance:
        params['class_weight'] = 'balanced'

    # Train the classifier
    classifier = ExtraTreesClassifier(**params)
    classifier.fit(X_train, y_train)

    # Visualize the training and testing results
    visualize_classifier(classifier, X_train, y_train, 'Тренувальні
дані')
    visualize_classifier(classifier, X_test, y_test, 'Тестовий набір
даних')

    # Evaluate classifier performance
    class_names = ['Class-0', 'Class-1']
    print("\n" + "#" * 40)
    print("Classifier performance on training dataset\n")
    print(classification_report(y_train, classifier.predict(X_train),
target_names=class_names))
    print("#" * 40 + "\n")
    print("Classifier performance on test dataset\n")
    print(classification_report(y_test, classifier.predict(X_test),
target_names=class_names))
    print("#" * 40 + "\n")

def main():
    input_file = 'data_imbalance.txt'
    X, y = load_data(input_file)

    # Plot the input data
    plot_data(X, y)

    # Check for optional argument
    balance = len(sys.argv) > 1 and sys.argv[1] == 'balance'

    # Train and evaluate the classifier
    train_and_evaluate(X, y, balance=balance)
```

```
if __name__ == "__main__":
    main()
```

Завдання 2.3. Знаходження оптимальних навчальних параметрів за допомогою сіткового пошуку.

```
##### Searching optimal parameters for precision_weighted

Grid scores for the parameter grid:
{'max_depth': 2, 'n_estimators': 100} --> 0.85
{'max_depth': 4, 'n_estimators': 100} --> 0.841
{'max_depth': 7, 'n_estimators': 100} --> 0.844
{'max_depth': 12, 'n_estimators': 100} --> 0.832
{'max_depth': 16, 'n_estimators': 100} --> 0.816
{'max_depth': 4, 'n_estimators': 25} --> 0.846
{'max_depth': 4, 'n_estimators': 50} --> 0.84
{'max_depth': 4, 'n_estimators': 100} --> 0.841
{'max_depth': 4, 'n_estimators': 250} --> 0.845

Best parameters: {'max_depth': 2, 'n_estimators': 100}

Performance report:
              precision    recall  f1-score   support

         0.0       0.94      0.81      0.87        79
         1.0       0.81      0.86      0.83        70
         2.0       0.83      0.91      0.87        76

    accuracy                           0.86       225
   macro avg       0.86      0.86      0.86       225
weighted avg       0.86      0.86      0.86       225
```

```
##### Searching optimal parameters for recall_weighted

Grid scores for the parameter grid:
{'max_depth': 2, 'n_estimators': 100} --> 0.843
{'max_depth': 4, 'n_estimators': 100} --> 0.837
{'max_depth': 7, 'n_estimators': 100} --> 0.841
{'max_depth': 12, 'n_estimators': 100} --> 0.83
{'max_depth': 16, 'n_estimators': 100} --> 0.815
{'max_depth': 4, 'n_estimators': 25} --> 0.843
{'max_depth': 4, 'n_estimators': 50} --> 0.836
{'max_depth': 4, 'n_estimators': 100} --> 0.837
{'max_depth': 4, 'n_estimators': 250} --> 0.841

Best parameters: {'max_depth': 2, 'n_estimators': 100}

Performance report:
              precision    recall  f1-score   support

         0.0       0.94      0.81      0.87        79
         1.0       0.81      0.86      0.83        70
         2.0       0.83      0.91      0.87        76

    accuracy                           0.86       225
   macro avg       0.86      0.86      0.86       225
weighted avg       0.86      0.86      0.86       225
```

Лістинг:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import classification_report
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.ensemble import ExtraTreesClassifier
from utilities import visualize_classifier

input_file = 'data_random_forests.txt'
data = np.loadtxt(input_file, delimiter=',')
X, y = data[:, :-1], data[:, -1]
```

```
class_0 = np.array(X[y == 0])
class_1 = np.array(X[y == 1])
class_2 = np.array(X[y == 2])

X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.25, random_state=5)

parameter_grid = [
    {'n_estimators': [100], 'max_depth': [2, 4, 7, 12, 16]},
    {'max_depth': [4], 'n_estimators': [25, 50, 100, 250]}
]

metrics = ['precision_weighted', 'recall_weighted']

for metric in metrics:
    print("\n##### Searching optimal parameters for", metric)

    classifier = GridSearchCV(ExtraTreesClassifier(random_state=0),
parameter_grid, cv=5, scoring=metric)
    classifier.fit(X_train, y_train)

    print("\nGrid scores for the parameter grid:")
    for params, avg_score in zip(classifier.cv_results_['params'],
classifier.cv_results_['mean_test_score']):
        print(params, '-->', round(avg_score, 3))

    print("\nBest parameters:", classifier.best_params_)

    y_pred = classifier.predict(X_test)
    print("\nPerformance report: \n")
    print(classification_report(y_test, y_pred))
```

Завдання 2.4. Обчислення відносної важливості ознак. load_boston було видалено з нових версій scikit-learn, тому було використано: from sklearn.datasets import fetch_california_housing

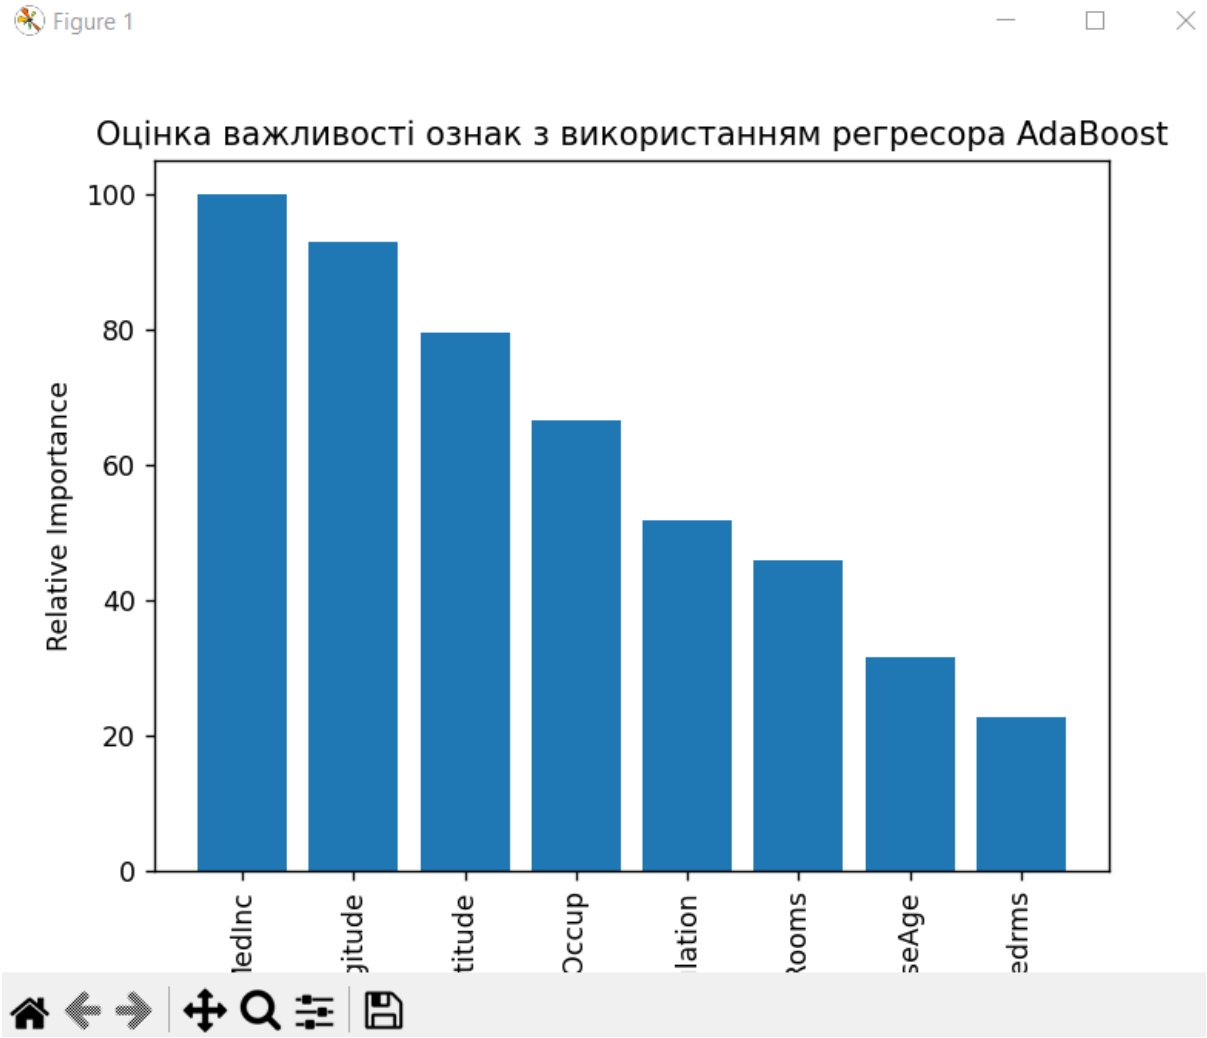


```
ADABOOST REGRESSOR
Mean squared error = 1.18
Explained variance score = 0.47
```

Лістинг:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import AdaBoostRegressor
from sklearn.datasets import fetch_california_housing
from sklearn.metrics import mean_squared_error,
explained_variance_score
from sklearn.model_selection import train_test_split
from sklearn.utils import shuffle
```

```
housing_data = fetch_california_housing()

X, y = shuffle(housing_data.data, housing_data.target, random_state=7)

X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=7)

regressor = AdaBoostRegressor(DecisionTreeRegressor(max_depth=4),
n_estimators=400, random_state=7)
regressor.fit(X_train, y_train)

y_pred = regressor.predict(X_test)

mse = mean_squared_error(y_test, y_pred)
evs = explained_variance_score(y_test, y_pred)
print("\nADABOOST REGRESSOR")
print("Mean squared error =", round(mse, 2))
print("Explained variance score =", round(evs, 2))

feature_importances = regressor.feature_importances_
feature_names = housing_data.feature_names

feature_importances = 100.0 * (feature_importances /
max(feature_importances))
index_sorted = np.flipud(np.argsort(feature_importances))
pos = np.arange(index_sorted.shape[0]) + 0.5

plt.figure()
plt.bar(pos, feature_importances[index_sorted], align='center')
plt.xticks(pos, np.array(feature_names)[index_sorted], rotation=90)
plt.ylabel("Relative Importance")
plt.title("Оцінка важливості ознак з використанням регресора AdaBoost")
plt.show()
```

Завдання 2.5. Прогнозування інтенсивності дорожнього руху за допомогою класифікатора на основі гранично випадкових лісів.

```
Mean absolute error: 7.42
Predicted traffic: 26
```

Лістинг:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import classification_report, mean_absolute_error
from sklearn.model_selection import train_test_split
from sklearn import preprocessing
from sklearn.ensemble import ExtraTreesRegressor

input_file = 'traffic_data.txt'
data = []

with open(input_file, 'r') as f:
    for line in f:
        items = line.strip().split(',')
        data.append(items)

data = np.array(data)

label_encoders = []
X_encoded = np.empty_like(data, dtype=float)

for i, value in enumerate(data[0]):
    if value.isdigit():
        X_encoded[:, i] = data[:, i]
    else:
        encoder = preprocessing.LabelEncoder()
        X_encoded[:, i] = encoder.fit_transform(data[:, i])
        label_encoders.append(encoder)

X = X_encoded[:, :-1].astype(int)
y = X_encoded[:, -1].astype(int)

X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.25, random_state=5)

params = {'n_estimators': 100, 'max_depth': 4, 'random_state': 0}
regressor = ExtraTreesRegressor(**params)
regressor.fit(X_train, y_train)
```

```
y_pred = regressor.predict(X_test)
mae = mean_absolute_error(y_test, y_pred)
print(f"Mean absolute error: {mae:.2f}")

test_datapoint = ['Saturday', '10:20', 'Atlanta', 'no']
test_datapoint_encoded = []

for i, value in enumerate(test_datapoint):
    if value.isdigit():
        test_datapoint_encoded.append(int(value))
    else:
        encoder = label_encoders.pop(0)
        test_datapoint_encoded.append(encoder.transform([value])[0])

test_datapoint_encoded = np.array(test_datapoint_encoded)

predicted_traffic = regressor.predict([test_datapoint_encoded])[0]
print(f"Predicted traffic: {int(predicted_traffic)}")
```

Git: https://github.com/PavlenkoOks/AI